



GRADO EN ECONOMÍA

Curso Académico 2025/2026

RA-IVX en regresiones casi integradas: asimetría y aplicación a la curva de Phillips

Trabajo de Fin de Grado

Enrique Ruiz de Almirón Da Silva

NIU: 100476072

Tutor: Nazarii Shalis

25 de Junio de 2026

Resumen

En este trabajo hemos analizado la literatura que rodea a las regresiones predictivas con regresores altamente persistentes y las distorsiones que las afectan generando serios problemas de inferencia, así como las principales soluciones que se han construido alrededor de estos. Entre ellos analizamos el sesgo de Stambaugh (1999) y la distribución asintótica a la que convergen los t-stats Cavanagh, Elliott y Stock (1995). Frente a estos problemas, el marco IVX de Kostakis, Magdalinos y Stamatogiannis (2015) se ha constituido como una referencia, pero Hosseinkouchack y Demetrescu (2021) advierten que el estadístico t sigue mostrando una no-centralidad de muestra finita que se traduce (bajo correlación negativa de las innovaciones) en un sesgo positivo del estimador puntual de IVX. Este trabajo estudia el estimador RA-IVX de Demetrescu y Rodrigues (2022) que, basándose en una aumentación de la regresión mediante los residuos de la autorregresión del regresor, consiguen corregir dicho sesgo, y documentamos vía Monte Carlo una asimetría no descrita: la ventaja de RA-IVX frente a IVX es mayor bajo coeficientes negativos, donde la corrección de sesgo y la reducción de varianza operan en la misma dirección en vez de contrarrestarse. Esta propiedad motiva nuestra aplicación empírica a la curva de Phillips, cuyo coeficiente teórico es negativo y cuyo regresor (la tasa de desempleo) es casi integrado. Los resultados para la submuestra Bernanke/Yellen/Powell, donde OLS e IVX no alcanzan significatividad, muestran que RA-IVX sí la recupera al 10 %, ilustrando cómo la ventaja puede materializarse en datos macroeconómicos reales.

Abstract

In this work we have analyzed the literature surrounding predictive regressions with highly persistent regressors and the distortions that affect them, generating serious inference problems, as well as the main solutions that have been developed around them. Among these, we analyze the Stambaugh (1999) bias and the asymptotic distribution to which the t-stats converge, following Cavanagh, Elliott and Stock (1995). Faced with these problems, the IVX framework of Kostakis, Magdalinos and Stamatogiannis (2015) has established itself as a benchmark, but Hosseinkouchack and Demetrescu (2021) warn that the t-statistic still exhibits a finite-sample noncentrality that translates (under negative correlation of the innovations) into a positive bias in the IVX point estimator. This work studies the RA-IVX estimator of Demetrescu and Rodrigues (2022), which, based on augmenting the regression with the residuals from the regressor's autoregression, succeeds in correcting this bias, and we document via Monte Carlo simulation a previously undescribed asymmetry: the advantage of RA-IVX over IVX is greater under negative coefficients, where the bias correction and the variance reduction operate in the same direction rather than offsetting each other. This property motivates our empirical application to the Phillips curve, whose theoretical coefficient is negative and whose regressor (the unemployment rate) is nearly integrated. The results for the Bernanke/Yellen/Powell subsample, where OLS and IVX fail to achieve significance, show that RA-IVX does recover it at the 10 % level, illustrating how the advantage can materialize in real macroeconomic data.

Índice

1. Desafíos Econométricos en las Regresiones Predictivas	2
1.1. Sesgo en Muestra Finita del Estimador OLS	3
1.2. Asintótica No Estándar: Por Qué Falla el Test t	4
1.3. Métodos de Corrección de Sesgo	6
1.4. Procedimientos de Inferencia Robusta: Campbell y Yogo (2006)	7
1.5. El Marco IVX	8
2. Evidencia de Monte Carlo	11
3. Una Aplicación Empírica: La Curva de Phillips	14
3.1. Modelo, Datos y Estrategia de Estimación	15
3.2. Resultados	17
3.2.1. Eurozona	17
3.2.2. Estados Unidos	17
4. Conclusión	19
5. Tablas y gráficos	21
A. La descomposición del sesgo de Stambaugh–Kendall	26
B. Estrategia de Estimación Curva de Phillips	27

Lista de Tablas y Gráficos

1.	Tamaño empírico de los contrastes bajo H_0	21
2.	Resultados Monte Carlo: sesgo medio y distribución del estadístico t ($n = 100$, $\rho = 0,99$, $\rho_{uv} = -0,9$, $N_{sim} = 5000$).	21
3.	Potencia empírica para $n = 50$, grid completo de β	22
4.	Diagnósticos de Persistencia y Endogeneidad	22
5.	Resumen de los Resultados de las Regresiones Predictivas	23

Gráficos

1.	Figure 1. Empirical size at the 5 % level. $\beta = 0$, $\rho_{uv} = -0.9$, $N_{sim} = 2,000$	24
2.	Figure 2. Empirical power at the 5 % level. $\rho = 0,99$, $\rho_{uv} = -0,9$, $N_{sim} = 2,000$	24
3.	Figure 3. Finite-sample t -statistic distributions. $\rho = 0,99$, $N_{sim} = 5,000$	25

Declaración de Uso Responsable de Inteligencia Artificial Generativa:

Declaro haber utilizado la herramienta de IA de ChatGPT de OpenAI con la única finalidad de mejorar el estilo y claridad del texto que he escrito. En ningún momento la he utilizado para generar texto de manera automática a partir de textos de terceros, obtener fuentes bibliográficas, generar código de programación o interpretar los resultados de mi trabajo.

Las regresiones predictivas son una de las herramientas más utilizadas dentro de la economía y las finanzas. Su objetivo es determinar si una variable observada en el presente contiene información sobre la evolución futura de otra variable. Si bien estas regresiones forman parte desde hace tiempo del instrumental de previsión económica, lo que tiene un origen mucho más concreto es el conjunto de problemas econométricos que nos ocupa en este trabajo y que nace en el seno de la economía financiera.

A partir de los trabajos de Fama y French (1988) y Campbell y Shiller (1988), una extensa literatura abordó la cuestión de si los rendimientos futuros de los activos podían predecirse a partir de variables de valoración observadas en el presente como los dividend yields o los ratios precio-beneficio. La hipótesis subyacente era sencilla: valoraciones relativamente bajas debían asociarse a rendimientos futuros más elevados. Sin embargo, la propia naturaleza de los predictores utilizados para responder a esta pregunta acabaría dando lugar a una extensa literatura econométrica dedicada a estudiar las propiedades de estas regresiones y la validez de la inferencia obtenida a partir de ellas.

El motivo es que estos predictores financieros compartían dos rasgos problemáticos. Por un lado, sus valores se movían con extrema lentitud. Por otro lado, sus innovaciones estaban fuertemente correlacionadas con las de los propios rendimientos. Bajo esta combinación, el estimador OLS de la pendiente hereda un sesgo de muestra finita y la distribución de su estadístico t deja de seguir una normal estándar, de forma que los contrastes de predictibilidad acababan rechazando en exceso Stambaugh (1999). La literatura ha respondido por dos caminos que acaban confluyendo que son las correcciones de sesgo y la recuperación de la inferencia normal. Dentro del segundo camino, el método de variables instrumentales IVX de Kostakis, Magdalinos y Stamatogiannis (2015) se ha convertido en la referencia, y sobre este método, Demetrescu y Rodrigues (2022) acaban construyendo el estimador RA-IVX, que combina ambas correcciones al mejorar la regresión añadiendo los residuos del predictor. Hay un aspecto de este sesgo en el que la literatura no se ha centrado, ya que no ha sido su objeto de estudio. El sesgo de Stambaugh tiene signo: bajo la correlación negativa típica de los predictores financieros, tiende a ser positivo, y como en esas aplicaciones el efecto esperado también es positivo, el sesgo opera en la misma dirección que la señal que se busca detectar. La región opuesta, en la que el efecto esperado es

negativo, ha recibido menos atención.

En este trabajo examinamos el problema de las regresiones predictivas con regresores altamente persistentes y las distintas soluciones que ofrece la literatura. Revisamos mediante una simulación de Monte Carlo el comportamiento en muestras finitas de RA-IVX frente a IVX y OLS, centrándonos en la ventaja asimétrica que surge cuando el efecto verdadero es negativo. Finalmente, llevamos el método fuera de su habitat natural: a la curva de Phillips, donde la teoría predice una relación negativa entre desempleo e inflación.

1. Desafíos Econométricos en las Regresiones Predictivas

Las regresiones predictivas con regresores persistentes generan dos problemas relacionados pero que deben entenderse como lógicamente separados. El primero es un problema de muestra finita; esto es, el estimador OLS de β está sistemáticamente sesgado. El segundo es un problema de naturaleza asintótica que persiste con cualquier cantidad de datos: incluso después de corregir el sesgo, los estadísticos t utilizados para evaluar la significatividad no presentan buen comportamiento. La regresión predictiva que estudiamos, junto con el proceso que gobierna su predictor siguen:

$$r_{t+1} = \alpha + \beta x_t + u_{t+1}, \quad (1)$$

$$x_{t+1} = \mu + \rho x_t + v_{t+1}, \quad (2)$$

donde r_{t+1} representa los rendimientos futuros en exceso, x_t el predictor observado en t , y ρ el parámetro que marca su persistencia. En función de este parámetro, podríamos tener estacionariedad, integración, o todo un rango de posibilidades intermedias. Dos características de este sistema podrían provocar distorsiones. La primera es la alta persistencia de los ratios financieros, una lenta disipación de los shocks que dificulta distinguirlos de paseos aleatorio. En segundo lugar, las innovaciones de las expresiones anteriores, u_{t+1} y v_{t+1} , están mecánicamente correlacionadas, ya que ambas dependen de los precios de los activos (el predictor se construye a partir de precios, y los rendimientos vienen determinados por las variaciones de precio). Veremos en las próximas secciones que ninguna de las dos características es fatal por sí sola, sino que,

conjuntamente, generan las dificultades inferenciales que están en el centro de esta literatura.

1.1. Sesgo en Muestra Finita del Estimador OLS

Bajo estas características Stambaugh (1999) demostró que el estimador OLS de β contiene un sesgo en muestras finitas. No se trata de un problema estándar de endogeneidad, ya que x_t y u_{t+1} son ortogonales en el tiempo, y por tanto OLS seguirá siendo consistente asintóticamente. El fallo es más sutil: En una regresión normal i.i.d., la ortogonalidad entre el regresor y el término de error es suficiente para garantizar insesgadez. Cada observación es una extracción independiente; de esta forma, la media muestral hereda el momento poblacional y OLS se comporta correctamente. No obstante, en econometría de series temporales, las observaciones ya no son extracciones independientes. En función de la persistencia cada x_t puede depender de la observación anterior y a su vez esta de la anterior... El denominador del coeficiente, $\sum x_t^2$, por tanto, ya no es un objeto fijo, sino un objeto acumulado sobre la misma trayectoria realizada que el numerador, $\sum x_t u_{t+1}$.

Lo que determinará cuánto covaría el numerador y el denominador depende de dos condiciones: La primera es $\text{corr}(u, v) \neq 0$; es decir, la innovación del rendimiento y la innovación del predictor deben estar parcialmente impulsadas por el mismo shock, de modo que v_{t+1} aparezca tanto en el numerador a través de u_{t+1} como en el denominador a través del propio x_t^2 . La segunda es que $\rho \approx 1$, es decir, que el predictor sea lo bastante persistente como para que v_{t+1} se propague hacia adelante y permanezca integrado en $x_{t+2}, x_{t+3}, \dots$, la trayectoria de x_t . Si cualquiera de las dos condiciones falla, la covarianza tenderá a cero y la ortogonalidad volverá a ser suficiente.

Si proyectamos u_{t+1} sobre v_{t+1} y sustituimos en el ratio OLS, podemos obtener la derivación de Stambaugh (1999), que separa el sesgo en dos términos. Uno de ellos recoge la parte de la innovación del rendimiento que es ortogonal al predictor, no deja rastro por tanto en la trayectoria de x_t y de esta forma se anula en esperanza. El otro es un componente más problemático: un ratio de cantidades aleatorias correlacionadas, $\sum x_t v_{t+1} / \sum x_t^2$, que viene heredado del error de estimación OLS de ρ en el AR(1), $\hat{\rho} - \rho$. Su esperanza no se anula aunque el numerador tenga media cero. Esta esperanza es cuantificada por Kendall (1954) como

$\mathbb{E}[\hat{\rho} - \rho] \approx -(1 + 3\rho)/T$ en el entorno cercano a la raíz unitaria. Más detalles se ofrecen en el Anexo A. Stambaugh (1999) demuestra finalmente que la fórmula del sesgo puede expresarse como:

$$\text{Sesgo}(\hat{\beta}) = \frac{\sigma_{uv}}{\sigma_v^2} \cdot \mathbb{E}[\hat{\rho} - \rho] \quad (3)$$

Para los ratios de valoración, el signo es claro. El sesgo de kendal es negativo (subestima ρ) y σ_{uv} es también negativo ya que un aumento del precio del activo incrementa los rendimientos y reduce el ratio de precio. Del producto obtenemos un resultado positivo; por tanto, OLS sobreestima la predictibilidad. La implicación de esta derivación es que el sesgo tiene una forma analítica conocida que puede estimarse y restarse de $\hat{\beta}$. Esta es la lógica que siguen los métodos de corrección de sesgo. Sin embargo, veremos que corregir el estimador puntual no es suficiente para la inferencia. Ese problema tiene un origen distinto, como explica el siguiente apartado.

1.2. Asintótica No Estándar: Por Qué Falla el Test t

Supongamos que corregimos el estimador puntual restando el sesgo de Stambaugh; el problema de inferencia seguirá ya que su naturaleza es diferente.¹ Incluso con un estimador centrado, el estadístico t utilizado para el contraste de hipótesis no converge a una distribución normal estándar cuando trabajamos con predictores persistentes, y por tanto no podemos confiar en los valores críticos gaussianos.

¿De dónde viene este problema? Para gran parte de los predictores financieros, no es posible saber empíricamente si ρ es estrictamente menor o igual a uno. Los tests de raíz unitaria tienen poca potencia frente a alternativas locales cuando ρ se encuentra en la región LTU. Elliott, Rothenberg y Stock (1996) demostraron que incluso los tests de raíz unitaria más potentes tienen una capacidad limitada para detectar estacionariedad en estas regiones, especialmente con un número limitado de observaciones (tamaños con los que realmente trabajamos). Así pues, quedamos atrapados en una zona gris, donde ningún marco asintótico se aplica realmente y al

1.El sesgo, al fin y al cabo, es solo un problema de muestra finita. ¿Por qué?, Esto se debe a que Bajo a una estacionariedad fija el sesgo de kendal tiende a cero cuando $T \rightarrow \infty$, $\mathbb{E}[\hat{\rho} - \rho] \approx -(1 + 3\rho)/T \rightarrow 0$, de modo que la contaminación se nos va con suficientes datos.

forzar una elección, corremos el riesgo de mal especificar el modelo.

El marco de local-to-unity adopta un enfoque distinto: en lugar de asumir que ρ es conocido, trata el grado de persistencia como nuestro objeto de incertidumbre. Phillips (1987) lo introdujo, y Cavanagh, Elliott y Stock (1995) lo trasladaron a las regresiones predictivas. La idea consiste en escribir el coeficiente autorregresivo como $\rho_T = 1 + c/T$ con $c \leq 0$. De tal modo que la raíz se aproxima a uno a medida que crece la muestra, determinada por c : tendremos una raíz unitaria exacta cuando $c = 0$, y una estacionariedad creciente a medida que c decrezca.

Bajo esta parametrización, la suma parcial de x_t converge a un proceso denominado Ornstein–Uhlenbeck J_c . Podríamos decir que es como un movimiento browniano, pero atraído hacia la media con una fuerza proporcional a cuán negativo sea c . Cuando $c = 0$, no hay fuerza de reversión y, por tanto, el proceso se comporta como un verdadero movimiento browniano. Del mismo modo, cuanto más negativo se vuelve c , mayor es la fuerza de reversión a la media (es decir, la estacionariedad). Dado que J_c depende de c , distintos valores de c producirán distintos procesos y, por tanto, distintas distribuciones límite para cualquier estadístico construido a partir de x_t . Esto es precisamente lo que termina contaminando el estadístico t . Siguiendo a Cavanagh, Elliott y Stock (1995), la distribución límite de t es:

$$t_{\hat{\beta}} \Rightarrow \delta \cdot \frac{\int_0^1 J_c(r) dW_v(r)}{\left(\int_0^1 J_c(r)^2 dr\right)^{1/2}} + \sqrt{1 - \delta^2} \cdot Z, \quad (4)$$

donde $\delta = \sigma_{uv}/(\sigma_u \sigma_v)$ es la correlación de los shocks, $Z \sim N(0, 1)$, y J_c es el proceso gobernado por c . El segundo término es normal estándar e inofensivo, pero el primero no lo es, ya que contiene a J_c y dado que c no puede estimarse de forma consistente, no conocemos la distribución del estadístico t ni qué valores críticos deberían usarse. Hay dos casos que merecen atención. Si $\delta = 0$, el término no estándar desaparece y podemos confiar en los valores críticos gaussianos normales. Este es el único caso en el que la inferencia OLS es segura. En el otro caso, donde $\delta \neq 0$, que abarca cualquier ratio de valoración relevante, la distribución será no estándar y estará condicionada al c desconocido. El reto consiste, por tanto, en realizar inferencia válida sin conocer c . Existen dos respuestas principales: enfoques de Bonferroni como el de Campbell y Yogo (2006), y el marco IVX desarrollado por Kostakis, Magdalinos y Stamatogiannis (2015).

1.3. Métodos de Corrección de Sesgo

El punto de partida natural es aprovechar que el sesgo tiene una forma analítica conocida. Dado que el sesgo es de la forma: $\text{Sesgo}(\hat{\beta}) = (\sigma_{uv}/\sigma_v^2) \cdot \mathbb{E}[\hat{\rho} - \rho]$, bastaría con estimar esos componentes a partir de los datos y restar el sesgo de $\hat{\beta}_{OLS}$. Esta corrección ya estaba presente en Stambaugh (1999), incluida junto con el resultado original.

Amihud y Hurvich (2004) atacan el problema con el mismo espíritu pero desde un ángulo distinto. Su idea es que si v_t fuera observable, podría incluirse directamente como regresor: $y_t = \alpha + \beta x_{t-1} + \gamma v_t + \varepsilon_t$. En esta regresión aumentada, el nuevo término de error ε_t sería ortogonal a x_{t-1} una vez que la parte endógena se ha incluido como control en la regresión, y por tanto $\hat{\beta}$ sería exactamente insesgado. Sin embargo, v_t no es observable; la ecuación anterior es inviable en la práctica. La solución propuesta por AH consiste en sustituir el término por residuos corregidos de sesgo $\hat{v}_t^*$, obtenidos usando un coeficiente autorregresivo corregido $\hat{\rho}^* = \hat{\rho} + (1 + 3\hat{\rho})/T + \dots$. Esta corrección es esencial, ya que los residuos OLS ordinarios arrastran el sesgo de Kendall hacia $\hat{v}$. Siempre que $\hat{\rho}^*$ sea suficientemente preciso, el estadístico t de $\hat{\beta}$ en la regresión aumentada viable converge a $N(0, 1)$ tanto bajo estacionariedad como bajo casi integración. La limitación principal es que esta precisión se deteriora en la región próxima a la unidad; la corrección de $\hat{\rho}^*$ resulta así menos fiable precisamente en el límite donde más se necesitaría. La garantía es, por tanto, condicional: solo se sostiene si podemos estimar bien la persistencia. Algunos de los métodos discutidos en las siguientes secciones no necesitarán esto en absoluto.

Lewellen (2004) tomó un camino distinto que evita estimar ρ por completo. Estimar ρ de forma fiable es difícil precisamente en los casos en los que la corrección más importa, así que decidió eludir esta circularidad. ¿Cómo? Siendo conservador. Impone $\rho = 1$ directamente en la aproximación de Kendall, lo que da $\mathbb{E}[\hat{\rho} - \rho] \approx -4/T$, es decir, Lewellen contempla el peor escenario posible. Si el verdadero $\rho < 1$, se produce una pequeña sobrecorrección, pero ganamos robustez frente a la mala especificación de la persistencia. Lewellen demostró que este ajuste conservador debilitaría sustancialmente buena parte de la evidencia previa de predictibilidad de los rendimientos.

Estos tres métodos, cada uno a su manera, corrigen el estimador puntual. El problema de

inferencia, sin embargo, seguirá presente cuando ρ esté próximo a uno ya que, como vimos, la distribución del estadístico t depende de un c desconocido. La siguiente sección considera otro procedimiento que toma la incertidumbre sobre c como punto de partida.

1.4. Procedimientos de Inferencia Robusta: Campbell y Yogo (2006)

Los métodos anteriores abordan el problema desde el lado de la estimación: mejorar $\hat{\beta}$. Campbell y Yogo (2006) parten de un lugar distinto centrándose en la inferencia. Antes de describir la construcción de CY, es conveniente descartar la respuesta intermedia más natural: estimar c a partir de los datos, invertir un test ADF y condicionar la inferencia a esa estimación puntual. Sin embargo, esto no resuelve el problema ya que la imprecisión de $\hat{c}$ desplaza los valores críticos de c .² Campbell y Yogo (2006) evitan estimar c por completo mediante una construcción de Bonferroni. El primer paso consiste en acotar c en lugar de estimarlo: invertir un test de raíz unitaria sobre una rejilla de valores proporciona un intervalo de confianza (c_l, c_u) que contiene al verdadero c con probabilidad $1 - \eta_1$. El segundo paso es aprovechar el hecho de que, condicionando c , la distribución límite de t queda completamente caracterizada por la ecuación (4). Depende de c y de δ , pero de ninguna otra cantidad desconocida. Por tanto para cada c dentro de (c_l, c_u) , Campbell y Yogo invierten un estadístico t con corrección de sesgo para obtener un intervalo de confianza para β ; a continuación, toman la unión sobre todos los valores de c del intervalo de forma que la desigualdad de Bonferroni garantiza: $P(\beta \notin CI_\beta) \leq \eta_1 + \eta_2 = \eta$,

Esto significa que el test global controla el tamaño al nivel η sin requerir una estimación puntual de c . Pero esta robustez no es gratuita; la potencia se ve afectada. El nivel de significatividad total η debe repartirse entre las dos etapas: η_1 se destina a acotar c , y η_2 a contrastar β . Toda la significatividad asignada al primer paso deja de poder utilizarse para detectar predictibilidad. La incertidumbre sobre c no invalida el test, pero sí que reduce su capacidad para detectar predictibilidad.

2. Cavanagh, Elliott y Stock (1995) formalizan el siguiente argumento: si la distribución límite de nuestro estadístico t es sensible a c exactamente a la misma escala a la que $\hat{c}$ sigue siendo impreciso, entonces usar $\hat{c}$ en lugar de c desplaza los valores críticos en una cantidad que nunca se vuelve asintóticamente despreciable. Por tanto, condicionar sobre $\hat{c}$ no resuelve el problema.

No obstante, en Campbell y Yogo aparece una limitación más fundamental. La inferencia válida dentro de este marco exige que el investigador tome una posición sobre la clase de persistencia del predictor. Al final, la expresión de localización es un supuesto de modelización específico, y el test solo es válido dentro de ese supuesto. Si el proceso verdadero se aproxima a la unidad a una velocidad distinta de $1/T$, la asintótica local-to-unity deja de aplicarse. Esto motiva un procedimiento de inferencia que siga siendo válido independientemente de la persistencia del predictor y de la velocidad concreta a la que se aproxime a la unidad. Esa es la estrategia propuesta por Kostakis, Magdalinos y Stamatogiannis (2015).

1.5. El Marco IVX

Como explicamos, la principal limitación de CY no es simplemente que perdamos potencia al acotar c , sino también que el investigador no puede ser agnóstico respecto al verdadero proceso que sigue el predictor. Esto se debe a que el marco permite distintos grados de persistencia a través de c , pero fija la velocidad a la que el coeficiente se aproxima a uno, lo que plantea una pregunta natural: ¿podría realizarse una inferencia válida sobre β sin siquiera tomar postura sobre la persistencia? Kostakis, Magdalinos y Stamatogiannis (2015), apoyándose en el trabajo teórico de Magdalinos y Phillips (2009), responden con una idea elegante: en lugar de intentar determinar cuán persistente es el predictor y ajustar por ello, construyen un instrumento cuya distribución es asintóticamente normal independientemente del proceso verdadero que gobierne al predictor. Comienzan construyendo el instrumento a partir de la primera diferencia del predictor. Dado que x_t sigue: $x_t = \rho x_{t-1} + v_t$ con $\rho \approx 1$, las primeras diferencias $\Delta x_t = x_t - x_{t-1} \approx v_t$ son aproximadamente estacionarias eliminando así el componente LTU. Estos incrementos se introducen a continuación en una autorregresión artificial en la que el investigador elige una raíz artificial R_{nz} . las siguientes expresiones caracterizan el método:

$$\tilde{z}_t = R_{nz} \tilde{z}_{t-1} + \Delta x_t, \quad \tilde{z}_0 = 0, \quad R_{nz} = 1 - \frac{c_z}{n^\delta}, \quad c_z > 0, \quad 0 < \delta < 1. \quad (5)$$

La idea clave se aprecia mejor al comparar ambas raíces: mientras el predictor tiene raíz $\rho_T = 1 - c/T$, el instrumento usa $R_{nz} = 1 - c_z/T^\delta$. Como $T^{-\delta}$ decrece más lentamente que T^{-1}

cuando $\delta < 1$, el término que se resta es mayor para cualquier T finito, de modo que la raíz del instrumento permanece más alejada de la unidad que la del predictor. El instrumento sigue convergiendo hacia la unidad (lo que lo hace relevante), pero más lentamente que el regresor. Es precisamente este régimen de persistencia intermedia el que Magdalinos y Phillips (2009) denominaron integración moderada (*mild integration*), y es la propiedad que hace que IVX funcione. La intuición es análoga a la cancelación de escalas desconocidas en un estadístico pivotal.³

¿Por qué falla OLS? Dijimos que el predictor persistente x_{t-1} está correlacionado con el error de regresión u_t . Esto ocurriría porque el mismo shock que impulsaba x_t , concretamente v_t , estaba correlacionado con u_t , y debido a la alta persistencia esta correlación se acumula indefinidamente. De este modo, x_{t-1} y u_t quedaban entrelazados asintóticamente en el estadístico t , en el sentido de que el numerador y el denominador del test t no pueden separarse, y la distribución depende del c desconocido. IVX rompe esto sustituyendo x_{t-1} por el instrumento $\tilde{z}_{t-1}$, construido artificialmente para olvidar su pasado con la rapidez suficiente para que la correlación con u_t se anule asintóticamente. El instrumento se construye a partir de $\Delta x_t \approx v_t$, por lo que sigue correlacionado con x_{t-1} , lo que garantiza la relevancia del instrumento, pero, debido a la propiedad de integración moderada, su memoria decae con la rapidez suficiente para que, en el límite, sus sumas parciales converjan a un movimiento browniano independiente de u_t . Esta independencia implica que la incertidumbre del estimador IVX puede escribirse como una única escala desconocida, estimada mediante un objeto $\hat{Q}_H$. El estadístico de Wald se divide entonces entre $\hat{Q}_H$, cancelando la escala, y lo que queda tiene una distribución χ^2 que no depende de c . No obstante, la robustez de IVX no está exenta de coste. Sustituir x_{t-1} , que acumula señal a

3. La razón por la que IVX es capaz de restaurar la inferencia estándar se aprecia con mayor claridad mediante una analogía. Cuando estimamos una media normal con una varianza desconocida σ^2 , dividimos por $\hat{\sigma}/\sqrt{T}$ para obtener un estadístico pivotal. En realidad no conocemos la varianza, pero el denominador contiene exactamente la misma que el numerador, de modo que se cancela en el ratio. IVX sigue la misma operación, salvo que el objeto desconocido que se cancela no es un escalar, sino el proceso estocástico problemático J_c que codifica la persistencia desconocida de nuestro predictor. Siendo precisos, el instrumento no elimina J_c de la estimación; seguimos teniendo una dependencia respecto a c . Lo que el instrumento garantiza es que el proceso entra en el numerador y el denominador del Wald con una estructura idéntica, de modo que puede cancelarse en el ratio, algo que OLS no puede lograr

lo largo de T periodos, por el moderadamente integrado $\tilde{z}_{t-1}$, que acumula señal a lo largo de T^{δ_z} , implica trabajar con menos información. El test pierde potencia respecto a lo que podría lograrse si conociéramos el parámetro c . El parámetro δ_z nos controla este tradeoff. los valores que se más próximos a uno nos conservan más potencia pero también permiten que se filtre algo de persistencia, mientras que valores más cercanos a cero maximizan la robustez pero reducen mucho la potencia. En la práctica, ellos recomiendan $\delta_z = 0,95$.

A pesar de las ventajas de IVX, persiste otra limitación de muestra finita. Hosseinkouchack y Demetrescu (2021) demuestran que el estadístico $\tilde{t}_{ivx}$ presenta una no-centralidad residual en muestras finitas. Si bien el desarrollo es complejo, podríamos decir que se debe a que la construcción del instrumento z_{t-1} a partir de Δx_t filtrado no acaba de eliminar toda la correlación existente entre las innovaciones del regresor (v_t) y las del retorno u_t en muestras finitas, de modo que el instrumento, pese a estar diseñado para controlar la persistencia (*mild integration*), sigue heredando parte de esa correlación contemporánea que da lugar al sesgo de endogeneidad clásico - el mismo mecanismo de fondo que en Stambaugh(1999).

Demetrescu y Rodrigues (2022) reconocen el argumento y nos ofrecen una observación: si existe un desplazamiento sistemático en $\tilde{t}_{ivx}$, y dado que $\hat{\beta}_{IVX} - \beta = \tilde{t}_{ivx} \cdot se(\hat{\beta}_{IVX})$ y que el error estándar es, por construcción, siempre positivo, entonces esto se traduce en un sesgo de $\hat{\beta}_{IVX}$, lo que motiva su propuesta, que combina la intuición de corrección de sesgo de Amihud y Hurvich (2004) con el marco de variables instrumentales de KMS.

El punto de partida, igual que en AH, es la regresión aumentada inviable:

$$y_t = \alpha + \beta x_{t-1} + \gamma v_t + \varepsilon_t, \quad (6)$$

Al incluir v_t , ortogonalizamos ε_t , lo que hace que $\hat{\beta}$ sea exactamente insesgado. El procedimiento viable sustituye v_t por los residuos OLS simples $\hat{v}_t$ obtenidos de una autorregresión de orden p para x_t . Procedemos en dos etapas: primero regresamos $\ddot{y}_t$ sobre $\hat{v}_t$ por OLS $\tilde{y}_t = \ddot{y}_t - \hat{\gamma}\hat{v}_t$. Después se aplica IVX para regresar $\tilde{y}_t$ sobre $\ddot{x}_{t-1}$, obteniendo $\tilde{\beta}_{IVX}$. La principal diferencia respecto a Amihud y Hurvich (2004) es que, en lugar de usar residuos corregidos de sesgo $\hat{v}_t^*$, utilizamos residuos OLS simples. En el procedimiento AH, la calidad del residuo es crucial porque OLS es sensible a la precisión con la que se estima $\hat{\rho}$. En Demetrescu y Rodrigues (2022),

el instrumento IVX rompe esta dependencia. El instrumento converge más lentamente que OLS; por tanto, el error en $\hat{v}_t$ se reduce en relación con la señal de estimación. La misma convergencia lenta que reduce la potencia de IVX es lo que hace que la aumentación sea robusta frente a la calidad de los residuos.

Demetrescu y Rodrigues mejoran la inferencia por dos vías: en primer lugar, dado que la no-centralidad depende de la correlación entre u_t y v_t , al sustituir u_t por el residuo ortogonalizado $\varepsilon_t = u_t - \gamma v_t$, se elimina (caso infeasible) o se atenúa (caso feasible) la fuente de la correlación, centrando mejor la distribución de $\tilde{t}_{ivx}$ y mejorando el tamaño. De esto se deriva también que el sesgo de $\hat{\beta}_{IVX}$ se reduce. En segundo lugar, al proyectar la componente v_t fuera del error de regresión, la varianza residual se reduce de σ_u^2 a $\sigma_\varepsilon^2 < \sigma_u^2$, aumentando el ratio señal-ruido y haciendo más probable que se detecte predictibilidad genuina. No obstante, esta ganancia de potencia no está garantizada siempre, ya que al $se(\tilde{\beta}_{ivx})$ se le incorpora un término adicional $\hat{\gamma}^2 \hat{Q}_T$, que recoge el coste en incertidumbre de no poder trabajar con el verdadero v_t y tener que estimarlo.

2. Evidencia de Monte Carlo

Demetrescu y Rodrigues no se centran en el rango negativo de betas, ya que en su caso de interés (regresiones predictivas en finanzas) esperan betas teóricos positivos. No obstante, hay algo que nos hace pensar que RA-IVX podría ser especialmente ventajoso en el caso de betas negativos. Hosseinkouchack y Demetrescu demuestran que, bajo una correlación negativa de u_t y v_t , la distribución del estadístico t presenta una no centralidad que la desplaza hacia la derecha. Esto se traduciría por identidad a un sesgo sistemáticamente positivo de $\hat{\beta}_{IVX}$ incondicional al signo de beta verdadero, y al corregir este sesgo podríamos generar una ventaja asimétrica en la potencia. Revisamos con un experimento de Montecarlo el comportamiento en muestra finita de OLS, IVX y RA-IVX bajo condiciones que reflejan los entornos empíricos de la literatura, investigando la posible asimetría. Los datos se generan a partir de: $y_t = \beta x_{t-1} + u_t$ con $x_t = \rho x_{t-1} + v_t$, donde $(u_t, v_t)' \sim N(0, \Sigma)$, con varianzas unitarias y correlación contemporánea $\rho_{uv} = -0,9$. La persistencia se fija en $\rho = 0,99$, situando a x_t firmemente en el régimen casi integrado. El instrumento sigue la especificación KMS con $c_z = 1$ y $\delta_z = 0,95$. Los resultados

se basan en 2.000 réplicas para el análisis de potencia y 5.000 para el análisis distribucional. Nuestros tamaños muestrales abarcan $n \in \{50, 100, 150, 200, 300, 500\}$.

La Figura 1 representa las tasas de rechazo empíricas bajo $\beta = 0$ para distintos valores de persistencia y tamaños muestrales. El patrón confirma las predicciones teóricas de la Sección 2, el OLS sobrerrechaza de una forma severa en $\rho = 0,99$, superando el 20 % con $n = 50$. IVX logra una mejora sustancial, manteniéndose entre el 6–8 % incluso en la región LTU aunque sigue por encima de la banda de simulación del 95 %. RA-IVX parece ser el único procedimiento que se mantiene dentro de la banda, con tasas de rechazo entre el 3,5–5,5 % para todos los valores de ρ considerados, lo que nos confirma que la aumentación con $\hat{v}_t$ elimina la no centralidad residual que IVX conserva en muestras pequeñas. También podemos ver como al crecer n la distorsión de tamaño de OLS proveniente del sesgo de Kendall-Stambaugh se va reduciendo ya que el sesgo de Kendall tiende a cero $\mathbb{E}[\hat{\rho} - \rho] \approx -(1 + 3\rho)/T \rightarrow 0$.

La Figura 2 representa las distribuciones empíricas del estadístico t , contruido siempre para testear la hipótesis nula pero bajo distintos procesos generadores de datos (tres valores distintos de β) para $n = 100$. Bajo $\beta = 0$, observamos cómo el parámetro de no centralidad es directamente visible en la media: OLS = 1,24, IVX = 0,79, y RA-IVX = 0,38. Aquí, OLS presenta el peor comportamiento, seguido de IVX, debido a la no centralidad que RA-IVX consigue corregir parcialmente. Esto explica el sobrerrechazo documentado en la Figura 1.

Como comentamos, esta no-centralidad positiva se traduce también en un sesgo positivo de $\hat{\beta}_{IVX}$, y esperamos que dicho sesgo se vea reducido mediante el uso de la regresión aumentada. En la Tabla 2 puede verse el sesgo medio y el error estándar medio de los tres experimentos. Concluimos que los sesgos son aproximadamente del mismo tamaño y signo en los tres casos, y que todos se reducen por medio de la aumentación. También observamos una mejora vía reducción de la varianza.

Lo que suponemos, por tanto, es que el efecto sobre la potencia sea asimétrico según nos enfrentemos a un β teóricamente positivo o negativo. Bajo $H_0 : \beta = 0$, el sesgo positivo de IVX se traduce en sobretamaño y bajo las alternativas $\beta > 0$, ese mismo sesgo se sumaría al drift verdadero, generando un exceso de rechazo espurio (por encima de la potencia teórica correcta). Bajo alternativas $\beta < 0$, esperamos lo contrario, es decir, que el sesgo positivo al sumarse al

drift verdadero (que es negativo), acerque el estadístico t hacia el valor crítico, reduciendo así la probabilidad de rechazo. De esta forma el test estaría perdiendo la potencia para detectar una predictibilidad genuina. Este efecto de la no centralidad sobre el sesgo es asimétrico a diferencia del efecto de la varianza.

El efecto de la varianza por su parte es simétrico en el sentido de que una reducción del se aumenta el valor absoluto del t -stat y por tanto ayudar a capturar tanto un drift positivo como negativo.⁴ De esta forma esperamos lo siguiente en las distribuciones de t :

En el caso positivo encontramos dos efectos que se contrarrestan: por un lado, la reducción de la varianza nos permite capturar mejor el beta positivo, pero por otro lado la atenuación del sesgo positivo reducirá el t -stat. Estos efectos contrarios se contrarrestan, de forma que esperamos que las medias de los t -stats no se alejen tanto. Por su lado, en el lado negativo ambos efectos reman a la vez. La reducción de la varianza capta mejor el drift negativo, y la eliminación del sesgo positivo hace aún más negativo el beta. De esta forma esperamos que el t -stat del RA-IVX se aleje más del t -stat de IVX.

Esto que esperaríamos teóricamente queda confirmado por las medias de las distribuciones que se muestran en la Figura 3. En el caso positivo, la media de t_{ivx} supera a la de t_{ra} en apenas 0.12, una diferencia modesta, tal como anticipábamos. En cambio, bajo el beta negativo, la media de t_{ra} es 7.5 décimas más negativa que la de t_{ivx} , lo cual ya es de magnitud considerable. Esto nos confirma el canal que esperábamos: IVX al conservar el sesgo positivo, infrarrechaza la alternativa negativa, dejando de detectar como significativas señales negativas que si lo son.

Las curvas de potencia (Figura 2) nos confirman la asimetría anticipada. RA-IVX domina claramente a IVX en potencia bajo alternativas negativas, mientras que la diferencia en alternativas positivas favorece a IVX debido a un menor control del tamaño. En el Cuadro 3 observamos que la potencia en el caso $n = 50$ es casi el doble para alternativas menores o iguales a $-0,075$. Por ejemplo, para $-0,1$ somos capaces de detectar la alternativa el 21 % de las veces con RA-IVX frente al 11 % con IVX. Esta ventaja se va atenuando a medida que crece n y t_{ivx} se

4.El término proviene de la teoría de procesos estocásticos. Llamamos drift al desplazamiento sistemático de la media de la distribución límite del t -stat que atribuimos al valor verdadero de beta bajo una alternativa local; distinguiéndolo así des un desplazamiento de origen distinto (defecto de muestra finita, no dependiente de beta).

va acercando asintóticamente a la Normal, lo que podemos observar en la convergencia de las curvas a medida que n crece.

En conjunto el Monte Carlo confirma la motivación teórica: la no-centralidad de $\tilde{t}_{ivx}$ bajo una correlación negativa fija genera un sesgo de $\hat{\beta}_{IVX}$ positivo independiente de si el signo de beta es positivo o negativo. La eliminación de este sesgo via aumentación consistente en los tres casos corrige el tamaño del contraste bajo la nula y favorece restableciendo la potencia en betas negativos y reduce la potencia espuria de $\hat{\beta}_{IVX}$ en los casos de señales positivas. Es interesante como esto interactúa con el efecto de la reducción de la varianza que aumenta la potencia de forma simétrica. Esta mejora de potencia en el lado positivo es contrarrestada parcialmente por la reducción del sesgo positivo, en el lado negativo por su parte tanto la reducción de la varianza como la reducción del sesgo de beta colaboran y por tanto es donde esperamos mejores ventajas en muestras finitas.

3. Una Aplicación Empírica: La Curva de Phillips

Las metodologías econométricas que explicamos en la Sección 1 nacieron en el seno de la economía financiera. Sin embargo, las mismas patologías pueden surgir en cualquier regresión predictiva con regresores altamente persistentes. La curva de Phillips es un ejemplo natural. La tasa de desempleo es estructuralmente casi integrada, con raíces autorregresivas próximas a la unidad a lo largo de los horizontes muestrales macroeconómicos.

Lo que hace que la curva de Phillips resulte especialmente útil como aplicación empírica de las regresiones predictivas es cómo opera el sesgo de muestra finita. En la literatura de ratios financieros, vimos que una correlación negativa entre las innovaciones genera un sesgo positivo al multiplicarse con el sesgo de kendall (negativo también). En la curva de Phillips opera el mismo mecanismo: dado que desempleo e inflación suelen moverse en direcciones opuestas, esto genera una correlación negativa y, por tanto, un sesgo de Stambaugh positivo. Sin embargo, aquí aparece una idea clave: la teoría económica predice un β negativo; un exceso de oferta en el mercado de trabajo reduce los salarios y las presiones de precios y por tanto el mismo sesgo positivo que implica una sobrestimación de la predictibilidad en los casos clásicos podría tener el efecto contrario en la curva de phillips via atenuación del coeficiente negativo.

La consecuencia directa es que OLS puede empujar las estimaciones hacia cero, fallando en detectar predictibilidad no porque la relación verdadera esté ausente, sino porque el sesgo suprime la señal por debajo de los umbrales convencionales de significatividad. El estimador IVX por su parte, aunque corrige la inconsistencia de OLS bajo persistencia, no está exento de un problema análogo cuando nos encontramos en muestras finitas. La no centralidad positiva del estadístico t_{ivx} bajo correlación negativa documentada en Hosseinkouchack y Demetrescu (2021) se traslada a un sesgo positivo del propio $\hat{\beta}_{IVX}$ que adopta en cierta forma ese comportamiento del sesgo de Stambaugh (1999) al reducir la significancia de betas positivos. Frente a esto RA-IVX al atenuar la fuente de no centralidad (la correlación efectiva de los errores), recupera una potencia superior a la de ambos OLS e IVX.

Este ejercicio empírico se convierte en un test natural: en las submuestras donde los diagnósticos predicen atenuación, ¿recuperará RA-IVX una significatividad que ni OLS ni IVX alcanzan?

3.1. Modelo, Datos y Estrategia de Estimación

La regresión predictiva adopta la siguiente forma: $\pi_{t+1} = \alpha + \beta x_t + \varepsilon_{t+1}$

Estados Unidos. La inflación se construye como $\pi_t = 100 \cdot \Delta \log(\text{CPI}_t)$, donde CPI_t es el Índice de Precios al Consumo para Todos los Consumidores Urbanos (serie CPIAUCSL). La tasa de desempleo x_t se obtiene directamente en niveles (serie UNRATE). Ambas series se extraen del conjunto de datos FRED-MD de McCracken y Ng (2016).

Eurozona. La inflación se construye como $\pi_t = 100 \cdot \Delta \log(\text{HICP}_t)$, donde HICP_t es el Índice Armonizado de Precios al Consumo. La tasa de desempleo x_t es la tasa de desempleo total de la Eurozona. Ambas series se extraen del conjunto de datos EA-MD-QD de Barigozzi, Lissona y Tonni (2024). No se aplican transformaciones adicionales más allá de la diferencia logarítmica para la inflación.

Los diagnósticos de la Tabla 4 confirman que la regresión se encuadra dentro del contexto de las regresiones predictivas con regresores altamente persistentes. Las asimetrías entre ambas variables son claras. Podemos ver que la inflación es estacionaria en la mayoría de las muestras. El test ADF rechaza la raíz unitaria a niveles de significatividad convencionales, con coeficientes

AR(1) que oscilan entre 0,32 y 0,64. La tasa de desempleo no lo es: sus coeficientes AR(1) superan 0,94 en todas las muestras, llegando incluso a 1,003 en la Eurozona, y el test ADF no logra rechazar la raíz unitaria en todas las muestras salvo en la muestra mensual completa de EE. UU.

No todas las submuestras, sin embargo, son igualmente válidas para la inferencia. La submuestra previa a Volcker para EE. UU. debería dejarse de lado si queremos ser rigurosos. La inflación en ese periodo no supera el test ADF, con un p -valor de 0,248 y coeficientes AR(1) de 0,648. El marco IVX exige una variable dependiente estacionaria, y si la propia inflación es casi integrada, la regresión predictiva ya no se ajusta a la teoría asintótica para la que se desarrolló IVX.

La correlación estimada de las innovaciones, $\widehat{\text{corr}}(u, v)$, son modestas en magnitud absoluta, lo que implica que los sesgos de muestra finita están presentes pero no son de gran magnitud. Esperamos que RA-IVX recupere significatividad frente a OLS e IVX en las submuestras donde la endogeneidad sea más relevante y que sean coincidentes cuando esta no lo sea.

Aplicamos tres estimadores a cada regresión: OLS, IVX y RA-IVX. OLS se estima por mínimos cuadrados sobre las series centradas, con errores estándar homocedásticos, y se incluye como referencia sesgada. IVX sigue la calibración de Kostakis, Magdalinos y Stamatogiannis (2015): se construye un instrumento mildly integrated a partir del predictor y se obtiene el estimador puntual $\hat{\beta}_{\text{IVX}} = \sum_t z_{t-1} \tilde{\pi}_{t+1} / \sum_t z_{t-1} \tilde{x}_t$, cuya inferencia es robusta a la persistencia y endogeneidad del regresor. La construcción recursiva del instrumento y la fórmula del error estándar se recogen en el Anexo B. RA-IVX (Demetrescu y Rodrigues, 2022) procede en dos pasos previos a IVX. Primero, ajustamos un $\text{AR}(p)$ al predictor por OLS y guardamos sus residuos $\hat{v}_t$, con p seleccionado por AIC. Segundo, añadimos $\hat{v}_t$ y aplicamos IVX a la regresión aumentada, obteniendo $\tilde{\beta}_{\text{IVX}}$ con varianza robusta a heterocedasticidad. El desarrollo completo se ofrece en el Anexo B

3.2. Resultados

3.2.1. Eurozona

Los resultados de la Eurozona cuentan una historia coherente. La muestra completa ofrece una predictibilidad robusta y significativa para los tres estimadores, con coeficientes agrupados alrededor de $\hat{\beta} = -0,042$. El signo es consistente con la teoría: un mayor desempleo predice una menor inflación. Además, la convergencia entre métodos es en sí misma informativa: con $\widehat{\text{corr}}(u, v)$ cercano a cero, la maquinaria de corrección de sesgo tiene poco que corregir, y los tres estimadores se comportan tal como predice la teoría cuando la endogeneidad es despreciable.

Los resultados por submuestras deben leerse con cautela. El periodo previo a 2008 abarca 93 meses frente a 202 del periodo posterior a 2008, lo que limita considerablemente la potencia estadística. Los coeficientes son algo menores en valor absoluto ($-0,036$ frente a $-0,042$), pero la ausencia de significatividad en la submuestra más temprana no puede atribuirse a una ausencia estructural de predictibilidad. Lo que los resultados sí establecen con firmeza es que la predictibilidad de la curva de Phillips es estadísticamente robusta en el periodo posterior a la crisis para los tres métodos.

En el caso europeo la poca endogeneidad y el poco cambio de los betas sugiere, lo que es coherente con correlaciones bajas sugiere que el instrumento apenas corrige. No obstante, el coste de eficiencia de las variables instrumentales que comentábamos en 1.5 (producto de una convergencia más lenta) si se paga en su totalidad como vemos en el aumento de los se. Esto ilustra el coste de robustez que se paga, incluso cuando a posteriori resulta no haber apenas endogeneidad que corregir. Es precisamente en otras submuestras donde dicha endogeneidad sea si es mas relevante donde este coste encuentra su contrapartida.

3.2.2. Estados Unidos

Los resultados de Estados Unidos presentan un panorama más matizado que el de la Eurozona, con una heterogeneidad sustancial entre los distintos subperiodos que la muestra completa oculta. No se encuentra predictibilidad significativa en la muestra completa, con estadísticos t muy por debajo de los umbrales convencionales en los tres métodos y un $\widehat{\text{corr}}$ de $-0,041$. Esto no nos sorprende, ya que promediar a través de regímenes con dinámicas opuestas

diluye mecánicamente cualquier señal específica de submuestra.

La submuestra de Volcker–Greenspan ofrece los resultados más llamativos, con coeficientes positivos y significativos para los tres estimadores. Este signo resulta contraintuitivo desde la perspectiva de una curva de Phillips orientada a la demanda, pero coincide con la literatura empírica sobre el periodo Volcker. El periodo Volcker estuvo dominado por shocks de oferta que elevaron simultáneamente el desempleo y la inflación, rompiendo la relación negativa estándar. los tres estimadores no distan mucho. En los siguientes periodos entramos en el caso que documentamos betas negativos y correlación negativa entre las innovaciones.

La Gran Moderación no produce resultados significativos en ningún método, lo que es consistente con el aplanamiento, ampliamente documentado, de la curva de Phillips durante el periodo (Blanchard et al., 2015). Una inflación estable y expectativas bien ancladas dejaron una variación insuficiente para que el desempleo tuviera un poder predictivo detectable. La curva de Phillips no desapareció estructuralmente: se volvió estadísticamente invisible porque la política monetaria comprimió con éxito la variación de una de las variables. No obstante, emerge un patrón sugerente: aunque el beta de OLS es prácticamente nulo, los estimadores de variables instrumentales recuperan un beta doce veces mayor en valor absoluto ($\hat{\beta}_{IVX} = \hat{\beta}_{RA-IVX} = -0,024$) y recuperamos algo de significancia con un t stat mas negativo. En este caso el sesgo positivo de Stambaugh atenúa visiblemente OLS hacia cero. La señal sigue siendo demasiado débil para superar los umbrales convencionales de significatividad, pero la dirección de la corrección del sesgo es exactamente la que predice la teoría. No obstante nos preguntamos por que no existe la ventaja que esperábamos y documentamos mediante el montecarlo? Esto se debe a que como podemos ver en el cuadro 4 el parámetro $\hat{\gamma}$ es de 0.025, prácticamente nulo en esta submuestra. La aumentación corrige sustrayendo $\hat{\gamma}\hat{v}_t$ de la regresión, es decir, hay poco que corregir. Esto ocurre por que la inflación en la gran moderación es muy poco volátil frente al desempleo, lo que reduce γ hacia cero aunque exista cierta correlación entre las series.

Por último, la submuestra de Bernanke/Yellen/Powell es donde la contribución metodológica es visible. Podemos ver cómo tanto OLS como IVX no alcanzan significatividad, con un $t_{OLS} = -1,305$ y un t_{IVX} algo mejor de $-1,439$. RA-IVX, sin embargo, parece recuperar una señal que OLS e IVX no detectan: alcanzamos significatividad al 10% con un t_{RA-IVX} de

$-1,969$. Con $\widehat{\text{corr}} = -0,103$, la endogeneidad no es despreciable, y el beta reportado es negativo, el entorno en el que las simulaciones otorgaron a RA-IVX su mayor ventaja.

Aquí solo opera uno de los canales que se explicaron en la sección 2. La corrección del sesgo positivo nos da un $\hat{\beta}$ más negativo ($-0,017$ frente a $-0,012$ de IVX) que empuja nuestro t hacia la región de rechazo. El segundo canal sin embargo no se materializa: la reducción de la varianza derivada de $\sigma_{\varepsilon}^2 < \sigma_u^2$. El error estandar de RA-IVX no es menor que el de IVX en esta submuestra lo que se debe a que la ganancia se ve contrarrestada por el coste de eficiencia de la estimación de $\hat{v}_t$.

4. Conclusión

Este trabajo ha examinado los desafíos econométricos que surgen en las regresiones predictivas con regresores altamente persistentes, recorriendo la literatura desde el sesgo de Stambaugh, pasando por la asintótica local-to-unity y los métodos de corrección de sesgo, hasta el marco IVX y la extensión aumentada por residuos de Demetrescu y Rodrigues (2022). Sobre esta base metodológica, hemos examinado las propiedades en muestra finita de OLS, IVX y RA-IVX mediante simulación de Monte Carlo, y aplicado estos métodos a la cuestión de la predictibilidad de la curva de Phillips.

Las simulaciones apuntan a que bajo alternativas positivas dos efectos contrarios de usar RA-IVX se pueden compensar de forma que la ventaja se atenué parcialmente. Bajo alternativas negativas estos dos efectos no se contrarrestan de forma que esperaríamos una mayor ventaja. Nuestra aplicación empírica con la submuestra Bernanke/Yellen/Powell es consistente con que esa ventaja documentada se puede materializa en datos reales, recuperando significancia frente a IVX y OLS.

Referencias

- [1] AMIHUD, Y., & HURVICH, C.M. (2004). Predictive regressions: a reduced-bias estimation method. *Journal of Financial and Quantitative Analysis*, 39(4), 813–841.
- [2] BARIGOZZI, M., LISSONA, C., & TONNI, L. (2024). Large datasets for the Euro Area and its member countries and the dynamic effects of the common monetary policy. *arXiv preprint arXiv:2410.05082*.

- [3] CAMPBELL, J.Y., & YOGO, M. (2006). Efficient tests of stock return predictability. *Journal of Financial Economics*, 81(1), 27–60.
- [4] CAMPBELL, J.Y., & SHILLER, R.J. (1988). Stock prices, earnings, and expected dividends. *Journal of Finance*, 43(3), 661–676.
- [5] CAVANAGH, C.L., ELLIOTT, G., & STOCK, J.H. (1995). Inference in models with nearly integrated regressors. *Econometric Theory*, 11(5), 1131–1147.
- [6] DEMETRESCU, M., & RODRIGUES, P.M.M. (2022). Residual-augmented IVX predictive regression. *Journal of Econometrics*, 227(2), 429–460.
- [7] ELLIOTT, G., ROTHENBERG, T.J., & STOCK, J.H. (1996). Efficient tests for an autoregressive unit root. *Econometrica*, 64(4), 813–836.
- [8] FAMA, E.F., & FRENCH, K.R. (1988). Dividend yields and expected stock returns. *Journal of Financial Economics*, 22(1), 3–25.
- [9] HOSSEINKOUCHACK, M., & DEMETRESCU, M. (2021). Finite-sample size control of IVX-based tests in predictive regressions. *Econometric Theory*, 37(4), 769–793.
- [10] KENDALL, M.G. (1954). Note on bias in the estimation of autocorrelation. *Biometrika*, 41, 403–404.
- [11] KOSTAKIS, A., MAGDALINOS, T., & STAMATOIANNIS, M.P. (2015). Robust econometric inference for stock return predictability. *Review of Financial Studies*, 28(5), 1506–1553.
- [12] LEWELLEN, J. (2004). Predicting returns with financial ratios. *Journal of Financial Economics*, 74(2), 209–235.
- [13] MAGDALINOS, T., & PHILLIPS, P.C.B. (2009). Limit theory for cointegrated systems with moderately integrated and moderately explosive regressors. *Econometric Theory*, 25, 482–526.
- [14] MCCracken, M.W., & NG, S. (2016). FRED-MD: A monthly database for macroeconomic research. *Journal of Business & Economic Statistics*, 34(4), 574–589.
- [15] PHILLIPS, P.C.B. (1987). Toward a unified asymptotic theory for autoregression. *Biometrika*, 74, 535–547.
- [16] STAMBAUGH, R.F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421.

5. Tablas y gráficos

Cuadro 1: Tamaño empírico de los contrastes bajo $H_0 : \beta = 0$, para distintos grados de persistencia ρ y tamaños muestrales n .

n	ρ	OLS	IVX	RA-IVX
50	0.70	0.066	0.072	0.053
	0.90	0.100	0.073	0.042
	0.95	0.160	0.080	0.042
	0.99	0.219	0.066	0.034
100	0.70	0.058	0.065	0.059
	0.90	0.072	0.058	0.041
	0.95	0.106	0.066	0.038
	0.99	0.199	0.059	0.035
200	0.70	0.056	0.061	0.056
	0.90	0.065	0.066	0.052
	0.95	0.078	0.064	0.038
	0.99	0.158	0.058	0.028
500	0.70	0.051	0.050	0.046
	0.90	0.069	0.064	0.062
	0.95	0.052	0.046	0.038
	0.99	0.102	0.059	0.031

Cuadro 2: Resultados Monte Carlo: sesgo medio y distribución del estadístico t ($n = 100$, $\rho = 0,99$, $\rho_{uv} = -0,9$, $N_{sim} = 5000$).

β_{true}	Estimador	$\bar{\hat{\beta}}$	Sesgo medio	$\bar{t}$	$\overline{SE}$
-0,075	IVX	-0,0328	0,0422	-1,1551	0,0471
	RA-IVX	-0,0576	0,0174	-1,9073	0,0371
0	IVX	0,0437	0,0437	0,7852	0,0476
	RA-IVX	0,0171	0,0171	0,3767	0,0379
0,075	IVX	0,1177	0,0427	2,6761	0,0473
	RA-IVX	0,0903	0,0153	2,5550	0,0383

Cuadro 3: Potencia empírica de los contrastes para $n = 50$, grid completo de β . Se muestra el caso de menor tamaño muestral con el detalle completo del grid de β por ser donde las diferencias entre estimadores son más pronunciadas; para n mayores los tres estimadores convergen rápidamente al mismo perfil en V (véase Figura 2)

β	OLS	IVX	RA-IVX
-0.150	0.312	0.250	0.458
-0.125	0.223	0.171	0.332
-0.100	0.141	0.117	0.217
-0.075	0.100	0.063	0.135
-0.050	0.096	0.050	0.066
-0.025	0.124	0.042	0.030
0.000	0.219	0.066	0.034
0.025	0.361	0.116	0.070
0.050	0.608	0.203	0.130
0.075	0.825	0.375	0.265
0.100	0.919	0.575	0.423
0.125	0.980	0.711	0.579
0.150	0.993	0.831	0.711

Cuadro 4: Diagnósticos de Persistencia y Endogeneidad

Muestra	T	Inflación		Desempleo		Endogeneidad	
		AR(1)	ADF p	AR(1)	ADF p	$\widehat{\text{corr}}(u, v)$	$\hat{\gamma}$
<i>Panel A: Eurozona — Mensual</i>							
Muestra completa	299	0.413	<0.05	1.003	0.220	-0.022	0.062
Pre-2008	93	0.136	<0.01	1.025	0.274	-0.064	0.539
Post-2008	202	0.453	<0.05	1.002	0.262	-0.032	0.013
<i>Panel B: Estados Unidos — Mensual</i>							
Muestra completa	795	0.621	<0.01	0.968	<0.05	-0.041	-0.072
Pre-Volcker	241	0.648	0.248	0.989	0.181	0.086	0.185
Volcker-Greenspan	313	0.605	<0.01	0.995	0.183	0.027	0.077
Gran Moderación	283	0.320	<0.01	0.987	0.175	-0.039	0.025
Bernanke/Yellen/Powell	230	0.540	<0.01	0.942	0.189	-0.103	-0.108

Notas: AR(1) estimado por OLS: $x_t = a + \rho x_{t-1} + u_t$. Test ADF con tendencia (drift); longitud de rezago = $\lfloor n^{1/3} \rfloor$; los p -valores se basan en los valores críticos de MacKinnon (1994). $\widehat{\text{corr}}(u, v)$ denota la correlación estimada entre la perturbación de la regresión predictiva y la innovación del proceso autorregresivo del desempleo. $\hat{\gamma}$ es el coeficiente OLS de proyectar $\tilde{\pi}_{t+1}$ sobre $\hat{v}_t$ en la etapa de aumentación de RA-IVX.

Cuadro 5: Resumen de los Resultados de las Regresiones Predictivas

Muestra	N	Coeficientes estimados (SE)			Estadísticos t			$\widehat{\text{corr}}(u, v)$
		$\hat{\beta}_{\text{OLS}}$	$\hat{\beta}_{\text{IVX}}$	$\hat{\beta}_{\text{RA-IVX}}$	t_{OLS}	t_{IVX}	$t_{\text{RA-IVX}}$	
<i>Panel A: Eurozona — Mensual</i>								
Muestra completa	299	−0,0434** (0,0086)	−0,0419** (0,0113)	−0,0419** (0,0113)	−5,049**	−3,721**	−3,712**	−0,022
Pre-2008	93	−0,0385 (0,0283)	−0,0362 (0,0386)	−0,0365 (0,0397)	−1,361	−0,938	−0,918	−0,064
Post-2008	202	−0,0425** (0,0100)	−0,0423** (0,0092)	−0,0423** (0,0092)	−4,234**	−4,584**	−4,583**	−0,032
<i>Panel B: Estados Unidos — Mensual</i>								
Muestra completa	795	0,0032 (0,0066)	0,0083 (0,0059)	0,0063 (0,0060)	0,494	1,407	1,051	−0,041
Volcker-Greenspan	313	0,0262* (0,0103)	0,0298* (0,0118)	0,0304** (0,0118)	2,537*	2,528*	2,579**	0,027
Gran Moderación	283	−0,0020 (0,0127)	−0,0241 (0,0319)	−0,0238 (0,0319)	−0,158	−0,756	−0,747	−0,039
Bernanke/Yellen/Powell	230	−0,0124 (0,0095)	−0,0119 (0,0083)	−0,0167* (0,0085)	−1,305	−1,439	−1,969*	−0,103

Notas: La tabla recoge los coeficientes estimados de las regresiones predictivas OLS, IVX y RA-IVX de la inflación sobre el desempleo, con el error estándar entre paréntesis inmediatamente debajo de cada coeficiente, el estadístico t correspondiente, y el tamaño de muestra N . $\widehat{\text{corr}}(u, v)$ denota la correlación estimada entre la perturbación de la regresión predictiva y la innovación del proceso autorregresivo del desempleo (común a los tres estimadores dentro de cada submuestra). Los niveles de significatividad se indican mediante *, ** y *** (10 %, 5 % y 1 %, respectivamente).




Figure 1: Figure 1. Empirical size at the 5% level. $\beta = 0$, $\rho_{uv} = -0.9$, $N_{sim} = 2,000$.




Figure 2: Figure 2. Empirical power at the 5% level. $\rho = 0.99$, $\rho_{uv} = -0.9$, $N_{sim} = 2,000$.




Figure 3: Figure 3. Finite-sample t -statistic distributions. $\rho = 0,99$, $N_{\text{sim}} = 5,000$.

A. La descomposición del sesgo de Stambaugh–Kendall

Partimos del estimador OLS de β en la regresión predictiva. Restando el valor poblacional, el error de estimación se escribe únicamente en términos de la innovación del rendimiento:

$$\hat{\beta} - \beta = \frac{\sum x_t u_{t+1}}{\sum x_t^2} \quad (7)$$

El sesgo aparece porque u_{t+1} y el predictor comparten información. Para verlo, separamos u_{t+1} en la parte que está vinculada a la dinámica de x y la parte que no lo está. Proyectando u_{t+1} sobre v_{t+1} obtenemos $u_{t+1} = \gamma v_{t+1} + \varepsilon_{t+1}$, con $\gamma = \sigma_{uv} / \sigma_v^2$ y $\varepsilon_{t+1} \perp v_{t+1}$ por construcción. Sustituyendo, obtenemos la descomposición de Stambaugh:

$$\hat{\beta} - \beta = \gamma \cdot \frac{\sum x_t v_{t+1}}{\sum x_t^2} + \frac{\sum x_t \varepsilon_{t+1}}{\sum x_t^2} \quad (8)$$

Los dos términos se comportan de manera distinta. ε_{t+1} es la parte de u_{t+1} ortogonal a v_{t+1} por construcción. Esto significa que no tiene relación con la dinámica del predictor. Dado que $x_{t+1} = \rho x_t + v_{t+1}$, lo único que desplaza a x es un shock v , de modo que ε_{t+1} no deja efecto en ningún x_s y por tanto no deja rastro en el denominador $\sum x_s^2$. Esto implica que, escribiendo A_ε para su numerador y B para el denominador, $\text{Cov}(A_\varepsilon, B) = 0$. El primer término no contribuirá al sesgo. El término en v es distinto. v_{t+1} es el shock propio del predictor, por lo que se filtra en $x_{t+1}, x_{t+2}, \dots$ y nunca abandona el denominador $\sum x_s^2$ a través de los valores futuros de x . El numerador y el denominador comparten el mismo shock, por lo que covarían. De hecho, el ratio $\sum x_t v_{t+1} / \sum x_t^2$ es exactamente el error OLS de ρ en el AR(1):

$$\hat{\rho} - \rho = \frac{\sum x_t v_{t+1}}{\sum x_t^2} \quad (9)$$

El sesgo en $\hat{\beta}$ se sigue por tanto directamente del sesgo en $\hat{\rho}$, escalado por γ ; Kendall (1954) ofrece la expresión analítica cerrada $\mathbb{E}[\hat{\rho} - \rho] \approx -(1 + 3\rho)/T$ bajo un comportamiento cercano a raíz unitaria.

B. Estrategia de Estimación Curva de Phillips

OLS se estima mediante mínimos cuadrados ordinarios sobre las series centradas $\ddot{\pi}_{t+1}$ y $\ddot{x}_t$, con errores estándar homocedásticos convencionales. Se incluye como referencia sesgada. El instrumento IVX se construye de forma recursiva como

$$z_t = \rho_z z_{t-1} + \Delta x_t, \quad z_0 = 0, \quad \rho_z = 1 - T^{-0.95}, \quad (10)$$

siguiendo la calibración de Kostakis, Magdalinos y Stamatogiannis (2015). El estimador puntual y los errores estándar son:

$$\hat{\beta}_{IVX} = \frac{\sum_t z_{t-1} \ddot{\pi}_{t+1}}{\sum_t z_{t-1} \ddot{x}_t}, \quad \widehat{se}_{IVX} = \frac{\sqrt{\hat{\sigma}_u^2 \cdot \sum_t z_{t-1}^2}}{|\sum_t z_{t-1} \ddot{x}_t|}. \quad (11)$$

donde $\hat{\sigma}_u^2 = n^{-1} \sum_t \hat{u}_{t+1}^2$ se calcula a partir de los residuos OLS de $\ddot{\pi}_{t+1}$ sobre $\ddot{x}_t$.

RA-IVX. Procede en dos etapas previas a la aplicación de IVX.

Paso 1 — aumentación con residuos. Se ajusta un $AR(p)$ a $\ddot{x}_t$ por OLS:

$$\ddot{x}_t = \sum_{j=1}^p \hat{\rho}_j \ddot{x}_{t-j} + \hat{v}_t, \quad (12)$$

con p seleccionado por AIC sobre $p \in \{0, \dots, p_{\max}\}$, $p_{\max} = \lfloor 4(T/100)^{1/4} \rfloor$. Se proyecta $\ddot{\pi}_{t+1}$ sobre $\hat{v}_t$ y se ortogonaliza:

$$\tilde{\pi}_{t+1} = \ddot{\pi}_{t+1} - \hat{\gamma} \hat{v}_t, \quad \hat{\gamma} = \frac{\sum_t \hat{v}_t \ddot{\pi}_{t+1}}{\sum_t \hat{v}_t^2}. \quad (13)$$

Paso 2. Se aplica IVX a $\tilde{\pi}_{t+1}$ sobre $\ddot{x}_t$ usando el mismo instrumento z_t , obteniendo $\tilde{\beta}_{IVX}$. El estimador de varianza es robusto a la heterocedasticidad:

$$\widehat{Var}(\tilde{\beta}_{IVX}) = \frac{\sum_t z_{t-1}^2 \tilde{\varepsilon}_{t+1}^2 + \hat{\gamma}^2 \hat{Q}}{(\sum_t z_{t-1} \ddot{x}_t)^2}, \quad (14)$$

donde $\tilde{\varepsilon}_{t+1}$ son los residuos de la proyección OLS conjunta de $\tilde{\pi}_{t+1}$ sobre $(\ddot{x}_t, \hat{v}_t)$, y $\hat{Q}$ es la

corrección tipo sándwich para la incertidumbre de estimación en $\hat{\gamma}$.